Regressão da nota média de filmes (TMDB): pré-processamento, modelagem e avaliação

Autor(a) — Engenharia de Computação
CEFET-MG Campus Divinópolis
Orientação: Prof. Alisson Marques da Silva

March 29, 2026

Abstract

Este relatório descreve um experimento completo de análise e regressão sobre dados de filmes do TMDB, com objetivo de prever a variável alvo `vote_average`. A base bruta foi filtrada e transformada; features numéricas e categóricas de alta cardinalidade foram tratadas; em seguida foram avaliados um preditor trivial (baseline), regressão linear regularizada (Ridge), Random Forest e *HistGradientBoosting*. Os resultados foram consolidados no conjunto de teste (métricas MAE, RMSE e R^2), com validação cruzada no treino para o melhor modelo, análise de importância e exemplos de filmes reais do hold-out. Os valores numéricos das tabelas de exemplos de filmes foram reproduzidos com o mesmo arquivo processado e o mesmo `random_state` do split utilizado no notebook de modelagem.

Contents

1nil**Introdução e objetivo** **3**

2 Dados e definição do problema **3**
2.1 Fonte e escopo . . . 3
2.2 Filtros de integridade . . . 3
2.3 Variáveis utilizadas . . . 3

3 Pré-processamento (Notebook 01) **3**
3.1 Transformações . . . 3
3.2 Análise exploratória (gráficos) . . . 4
3.3 Artefato salvo . . . 4

4 Modelagem experimental (Notebook 02) **4**
4.1 Divisão treino / teste . . . 4
4.2 Baseline . . . 4
4.3 Modelos avaliados . . . 4
4.4 Métricas . . . 4

5 Resultados numéricos (conjunto de teste) **4**
5.1 Tabela comparativa . . . 4
5.2 Validação cruzada (treino) . . . 5
5.3 Importância de features . . . 5

6 Visualizações (melhor modelo) **5**

7 Exemplos reais no conjunto de teste **5**
7.1 Top 10 filmes com maiores notas reais no teste 5
7.2 Amostra das primeiras 50 linhas da tabela de comparação 6

8 Discussão e limitações **7**

9 Conclusão **7**

1 Introdução e objetivo

O objetivo do trabalho é construir um modelo de **regressão** capaz de estimar a **nota média** atribuída pelos usuários (`vote_average`) a partir de atributos tabulares de filmes. O problema é relevante para disciplina de Inteligência Computacional por exigir um fluxo reprodutível: obtenção dos dados, limpeza, transformações justificadas, definição de métricas e comparação de algoritmos.

O relatório acompanha a estrutura dos notebooks desenvolvidos: (1) pré-processamento e análise exploratória; (2) modelagem, avaliação e estudos complementares.

2 Dados e definição do problema

2.1 Fonte e escopo

Utilizou-se o conjunto de filmes **TMDB** (arquivo `TMDB_movie_dataset_v11.csv` na pasta de dados brutos). A variável alvo é contínua (`vote_average`), em escala típica de 0 a 10.

2.2 Filtros de integridade

Para reduzir ruído e valores ausentes disfarçados de zero, aplicaram-se critérios alinhados à boa prática em dados de plataformas:

- **`vote_count`** > 50: notas com poucos votos são instáveis; exige-se um mínimo de participação.
- **`budget`** > 0 **e `revenue`** > 0: valores zero costumam indicar ausência de informação, não verdadeiro zero econômico.
- Remoção de linhas com valores ausentes nas colunas selecionadas após o recorte de colunas.

Após os filtros, permanecem **7.761** registros, número consistente com o relatório de pré-processamento.

2.3 Variáveis utilizadas

Além das numéricas (`runtime`, `vote_count`, `log_budget`, `log_revenue`, `log_popularity`, ano derivado de `release_date`), foram incorporadas representações categóricas:

- **Gêneros**: codificação *multilabel* por presença dos top-K gêneros mais frequentes ($K = 15$).
- **Produtoras**: top-K empresas ($K = 20$) e coluna binária `company_other` para produtoras fora do conjunto frequente.

Variáveis brutas `budget`, `revenue` e `popularity` foram substituídas por versões em escala logarítmica (`log_*`), e as colunas textuais `genres` e `production_companies` não entram no modelo após o *encoding* (evita redundância e dimensão desnecessária).

3 Pré-processamento (Notebook 01)

3.1 Transformações

- **Logaritmo**: aplicado a `budget`, `revenue` e `popularity` para reduzir assimetria e estabilizar relações com a alvo.
- **Ano**: extraído de `release_date` para capturar tendência temporal.
- **Nomes de colunas derivadas**: função auxiliar para nomes seguros de colunas *one-hot* (gêneros e produtoras).

3.2 Análise exploratória (gráficos)

Os gráficos gerados no notebook apoiam as decisões acima:

- **Histograma de `vote_average`**: mostra concentração típica da nota em torno de valores intermediários; a variância da alvo é limitada, o que afeta o R^2 alcançável.
- **Boxplots de `budget` e `revenue`**: em escala linear, *outliers* extremos; em escala log, visualização mais clara do "miolo" da distribuição — reforça o uso de log nas features.
- **Matriz de correlação**: variáveis numéricas têm correlação linear moderada com a nota; relações não lineares e interações justificam modelos de árvore e boosting.
- **Dispersões** (`budget`, `revenue`, `runtime`, `popularity` vs. nota): em escala log no eixo x, a relação costuma aparecer mais homogênea para variáveis financeiras.

3.3 Artefato salvo

O dataset processado foi exportado para `data/processed/movies_processed.csv`, utilizado no notebook seguinte.

4 Modelagem experimental (Notebook 02)

4.1 Divisão treino / teste

Utilizou-se `train_test_split` com **20%** para teste e `random_state=42` para reprodutibilidade. O mesmo particionamento é usado para todos os modelos.

4.2 Baseline

Preditor **constante**: para todo filme do teste, a predição é a **média de `vote_average` no treino**. Não usa features; serve como referência mínima.

4.3 Modelos avaliados

- **Ridge**: `Pipeline` com `StandardScaler` + `Ridge` ($\alpha = 1{,}0$).
- **Random Forest**: `n_estimators=200`.
- **HistGradientBoosting**: `max_iter=200`.

4.4 Métricas

- **MAE** (erro absoluto médio): interpreta-se em "pontos" na escala da nota.
- **RMSE**: penaliza erros grandes.
- R^2: fração da variância explicada (complementar ao MAE no contexto de nota subjetiva).

5 Resultados numéricos (conjunto de teste)

5.1 Tabela comparativa

A Tabela 1 resume o desempenho no **teste**. O melhor modelo segundo o MAE é o **HistGradientBoosting**.

Table 1: Comparação de modelos — conjunto de teste (métricas arredondadas).

Modelo	**MAE**	**RMSE**	R^2
HistGradientBoosting (`max_iter`=200)	0,3994	0,5502	0,5749
Random Forest (`n_estimators`=200)	0,4207	0,5695	0,5446
Ridge ($\alpha = 1{,}0$)	0,4817	0,6374	0,4295
Baseline (média do treino)	0,6718	0,8440	−0,0004

Análise: há ganho forte do baseline em relação aos modelos com features (MAE cai de ∼0,67 para ∼0,40). O R^2 do *HistGradientBoosting* indica que parte substancial da variância da nota é explicada pelas variáveis disponíveis, sem ser irrealisticamente alto (o que seria suspeito em dados de gosto).

5.2 Validação cruzada (treino)

No treino, foi aplicada validação cruzada (por exemplo, k-fold) ao *HistGradientBoosting* para reportar média e desvio das métricas entre *folds*. Isso mede **estabilidade** do modelo sem usar o conjunto de teste reservado; os números do teste permanecem o critério de generalização final em um único *hold-out*.

5.3 Importância de features

A **permutation importance** (e/ou importâncias nativas do modelo) foi usada para interpretar quais variáveis mais influenciam o MAE quando perturbadas. Testes com subconjunto apenas das features mais importantes podem **piorar** levemente o desempenho, pois informação útil pode estar distribuída em várias colunas correlacionadas — manter o modelo completo foi a decisão adotada.

6 Visualizações (melhor modelo)

Para o *HistGradientBoosting*:

- **Real vs. predito**: dispersão esperada em torno da diagonal; afastamentos indicam erros por filme.
- **Resíduos vs. predito**: verifica viés sistemático; idealmente centrados em zero sem padrão em funil.
- **Histograma dos resíduos** e **Q–Q**: avaliam a forma da distribuição dos erros em relação à normalidade (referência diagnóstica, não requisito do modelo).

7 Exemplos reais no conjunto de teste

Para apresentação, foram recuperados títulos a partir do arquivo processado, alinhando-se aos índices do `y_test`. As predições abaixo foram obtidas com o mesmo particionamento e o mesmo *HistGradientBoosting* (`max_iter`=200, `random_state`=42) utilizado na reprodução deste relatório.

7.1 Top 10 filmes com maiores notas reais no teste

A Tabela 2 lista os dez filmes com maior `nota_real` no conjunto de teste, com predição e erro (real − predito).

Table 2: Dez filmes com maiores notas reais no conjunto de teste (modelo HistGradientBoosting).

Título	**Real**	**Predito**	**Erro**
The Shawshank Redemption	8,702	8,515	0,187
The Green Mile	8,507	8,547	−0,040
Evanescence - Synthesis Live	8,500	6,381	2,119
The Good, the Bad and the Ugly	8,473	8,072	0,401
GoodFellas	8,464	8,329	0,135
Grave of the Fireflies	8,455	8,345	0,110
Cinema Paradiso	8,453	7,841	0,612
One Flew Over the Cuckoo's Nest	8,420	8,227	0,193
Howl's Moving Castle	8,402	8,094	0,308
The Lord of the Rings: The Fellowship of the Ring	8,402	8,198	0,204

Análise: a maioria dos erros é pequena em magnitude na escala 0–10; a linha *Evanescence - Synthesis Live* apresenta erro maior e merece menção na banca: títulos atípicos (concerto/gravação) podem não seguir o mesmo padrão que filmes de ficção, e o modelo pode subestimar a nota.

7.2 Amostra das primeiras 50 linhas da tabela de comparação

A Tabela 3 reproduz a ideia do `head(50)` do *DataFrame* de comparação (ordem das linhas do objeto), com título, nota real, nota predita e erro. Valores arredondados a três casas decimais.

Table 3: Amostra de 50 filmes do conjunto de teste (primeiras linhas da tabela de comparação).

Título	**Real**	**Predito**	**Erro**
Remember Me	7,102	7,391	−0,289
The Rescuers Down Under	6,616	6,461	0,155
Kramer vs. Kramer	7,555	7,216	0,339
King Kong	7,610	7,493	0,117
The Dressmaker	6,992	6,924	0,068
Heaven's Gate	6,740	6,765	−0,025
Unfinished Business	5,445	5,359	0,086
Sliver	5,446	6,381	−0,935
Babysitting 2	6,300	6,268	0,032
The Man with the Golden Arm	7,159	6,956	0,203
The Glass Castle	7,172	7,063	0,109
Instinct	6,383	6,079	0,304
Man Bites Dog	7,226	6,823	0,403
Idle Hands	6,131	5,994	0,137
Gigli	4,029	5,843	−1,814
The Gray Man	6,979	6,848	0,131
10 Things I Hate About You	7,580	7,691	−0,111
42nd Street	6,901	6,817	0,084
The 33	6,357	6,819	−0,462
The Bucket List	7,181	6,727	0,454
Darkest Hour	7,350	7,305	0,045
Everything Must Go	6,153	6,371	−0,218
Dark Water	6,755	5,857	0,898
Little Manhattan	7,175	6,321	0,854
BloodRayne 2: Deliverance	4,046	5,282	−1,236
The Postman Always Rings Twice	6,533	6,579	−0,046
High School	5,700	5,082	0,618
A Million Ways to Die in the West	6,008	6,470	−0,462

Continua na próxima página

Table 3 — continuação

Título	Real	Predito	Erro
Warriors of the Rainbow: Seediq Bale - Part 1: The Sun Flag	7,347	6,669	0,678
Talladega Nights: The Ballad of Ricky Bobby	6,346	5,875	0,471
Taps	6,800	6,636	0,164
Let the Sunshine In	5,243	6,154	−0,911
Midnight in Paris	7,535	6,653	0,882
Fur: An Imaginary Portrait of Diane Arbus	6,079	6,665	−0,586
La Femme Nikita	7,093	7,121	−0,028
Kantara	7,352	7,239	0,113
Uncommon Valor	6,170	6,181	−0,011
Junior	5,167	6,057	−0,890
Domino	5,929	6,268	−0,339
Brick Mansions	5,900	5,970	−0,070
Never Back Down	6,746	7,120	−0,374
Deadfall	5,900	5,875	0,025
Almost Heroes	5,512	5,126	0,386
Suck Me Shakespeer	7,024	6,876	0,148
I Smile Back	6,205	6,441	−0,236
25th Hour	7,332	7,685	−0,353
Last Knights	6,453	5,962	0,491
Hello, My Name Is Doris	6,447	6,737	−0,290
Cocoon	6,602	6,647	−0,045
Young Adult	5,796	6,473	−0,677

8 Discussão e limitações

- A nota **não é determinística**: gosto, época e efeitos de cultura TMDB limitam o teto de R^2.
- **Seleção de filmes**: filtros (`vote_count`, receita/orçamento positivos) alteram o domínio de aplicação do modelo.
- ***Leakage***: evitou-se usar a média do conjunto inteiro para baseline; o teste não deve participar do ajuste de hiperparâmetros sem validação cruzada.

9 Conclusão

O projeto implementou um *pipeline* reprodutível desde o CSV bruto até a comparação de modelos. O **HistGradientBoosting** apresentou o melhor desempenho no teste entre as alternativas estudadas, com MAE na ordem de **0,4** ponto na escala da nota, representando ganho substancial em relação ao baseline. A análise exploratória, as métricas e os gráficos de resíduo sustentam a discussão técnica; as tabelas com títulos reais ilustram o comportamento do modelo em casos concretos do *hold-out*.

Compilação: `pdflatex reports/relatorio_ic_TMDB.tex`